

# Preparação e Exploração avançada de dados com KNIME

LEI/MiEI @ 2024/2025, 2º sem






- Preparação de Dados
  - o Join, Concatenation, Sorter, Filter and Aggregations
- Preparação e Exploração Avançada de Dados
  - Missing Values Treatment, Binning, Feature Scaling, Outlier Detection
  - Feature Selection, Nominal Value Discretization, Feature Engineering
- Experimentação (hands on)






#### **A Machine Learning Pipeline**



(https://towardsdatascience.com/architecting-a-machine-learning-pipeline-a847f094d1c7)




#### Fluxo de Trabalho Típico @ Knime






Uma operação JOIN combina dados de diferentes fontes:








No KNIME estão disponíveis diversas combinações no nodo JOINER:





#### Concatenação Concatenation

União de colunas: CONCATENATE





#### Ordenação Sorter

Column Resorter

Altera a ordem das colunas de input, com base na definição dos parâmetros;

**→** #

Ordena as linhas com base na definição dos parâmetros;


Sorter

 Permite que as linhas sejam classificadas a partir da tabela da base de dados de entrada; DB Sorter










### Filtros *Filter*




### Filtro de Colunas Column Filter






#### Filtro de Linhas Row Filter






### Filtro de Linhas de Valores Nominais Nominal Value Row Filter






#### Filtro de Linhas Baseado em Regras Rule-based Row Filter






# Filtro de Linhas em JAVA *Snippet*JAVA *Snippet Row Filter*






# **Operações de Agregação Count and Percent**






### Operações de Agregação Unique Count, Missing Values Count and Mode






## **Operações de Agregação Concatenate**






# Operações de Agregação *Mean, Sum, Standard Deviation and Kurtosis*






### Operações de Agregação Min/Max vs First/Last







### Operações de Agregação Dates






### **Operações Avançadas de Agregação Pattern Based**









# **Operações Avançadas de Agregação Data Type Based**











# **Operações Avançadas de Agregação No Aggregation vs No Grouping**










#### Preparação Avançada de Dados


- Redimensionamento de atributos/ Feature scaling
- Deteção de valores atípicos/ Outlier detection
- Seleção de atributos/ Feature selection
- Tratamento de valores em falta/ Missing values treatment
- Enumeração de valores nominais/ Nominal value discretization
- Divisão em intervalos/ Binning
- Engenharia de atributos/ Feature engineering





### Redimensionamento de atributos Feature scaling

- Normalizar a gama de valores de atributos;
- Muitos classificadores usam métricas de distância (ex.: distância euclidiana) e, se um atributo tiver uma gama alargada de valores, a distância será definida por esse atributo em particular. Por isso, a gama de valores deve ser normalizada para que cada atributo possa contribuir proporcionalmente para a distância final.







### Redimensionamento de atributos Feature scaling

- Normalizar a gama de valores de atributos:
  - Normalização:

Redimensionar os dados para que todos os valores caiam no intervalo de 0 e 1, por exemplo.




$$z = (b - a) \frac{x - \min(x)}{\max(x) - \min(x)} + a$$






### Redimensionamento de atributos Feature scaling

- Normalizar a gama de valores de atributos:
  - Standardization (ou Z-score Normalization):
     Redimensionar a distribuição de valores para que a média dos valores observados seja 0 e o desvio padrão seja 1.
     Assume que os dados se ajustam a uma distribuição gaussiana com média e desvio padrão bem comportados, o que nem sempre é o caso.



$$z = \frac{x_i - \mu}{\sigma}$$






- Deteção de valores atípicos (outliers):
  - o Estratégias baseadas em estatística:
    - Box Plots
    - Z-Score (std. dev)

Box Plot

Estimated
Yearly Income






- Deteção de valores atípicos (outliers):
  - Estratégias baseadas em conhecimento

#### Rule-based Row Filter








- Deteção de valores atípicos (outliers):
  - Estratégias baseadas em conhecimento


#### Rule-based Row Filter







- Deteção de valores atípicos (outliers):
  - o Estratégias baseadas em modelos:
    - Isolation Forest
    - One-Class SVM
    - Minimum Covariance Determinant
    - ...






- Seleção de atributos:
  - O Que atributos devem ser usados para criar um modelo de previsão?
    - Selecionar um subconjunto de atributos mais importantes para reduzir a dimensionalidade;
  - A remoção de atributos pouco importantes:
    - Pode afetar significativamente o desempenho de um modelo;
    - Reduz o overfitting (menor probabilidade de tomar decisões com base em ruído);
    - Melhora a precisão;
    - Ajuda a reduzir a complexidade de um modelo (reduz o tempo de treino);
  - o 0 que podemos remover:
    - Atributos redundantes (duplicados);
    - Atributos irrelevantes e desnecessários (não úteis);
  - Métodos de seleção de atributos:
    - Métodos de filtro;
    - Métodos wrapper,
    - Métodos embebidos;



#### Métodos de Filtro:

o Remover uma *feature* se a percentagem de *missing values* for superior a um determinado valor estabelecido;





- O Usar o teste "chi-square" para medir o grau de dependência entre uma *feature* e o *target*.
  - Para cada feature calcular X<sup>2</sup>;
  - Normalizar X<sup>2</sup> e ordenar de forma decrescente;
  - Selecionar 'n' features com maior importância;
     (ou as que estão acima de um determinado limite)




#### Métodos de Filtro:

- 0 ...
- o Remover uma feature se o valor do desvio padrão for baixo;
- o Remover uma feature se o valor de skew for elevado;
- o Remover features com alta correlação;












#### Métodos de Filtro:

0 ...

- Principal Component Analysis (PCA):
  - Técnica usada para reduzir a dimensão do espaço de features;
  - O objetivo é reduzir o número de features sem perder (demasiado) conhecimento;
  - Uma aplicação comum de PCA é para visualização de dados de grande dimensão;





Scatter Plot PCA Analysis 1.0 0.8 0.6 0.4 0.2 Em 1 -0.2 -0.4 -0.6 -0.8 -0.8 -0.7 -0.6 -0.5 -0.4 -0.3 Reset Apply A Close A



- Métodos wrapper.
  - Utilizar técnicas de machine learning para selecionar as features mais importantes;
    - Selecionar um conjunto de *features* como um problema de pesquisa;
    - Preparar diferentes combinações;
    - Avaliar e comparar as diferentes combinações;
    - Medir a "utilidade" das features com base no desempenho do classificador;

#### Sequential Forward Selection








### Seleção de Atributos Feature Selection

### Métodos wrapper.

- o Utilizar técnicas de *machine learning* para selecionar as *features* mais importantes;
  - Selecionar um conjunto de features como um problema de pesquisa;
  - Preparar diferentes combinações;
  - Avaliar e comparar as diferentes combinações;
  - Medir a "utilidade" das features com base no desempenho do classificador;






### Tratamento de Valores em Falta *Missing Values*

- Tratamento de valores em falta:
  - Analisar cada atributo em relação ao número e proporção de valores em falta;
  - Decidir o que fazer:
    - Remover;
    - Calcular a média;
    - Interpolação linear;
    - · Criar máscaras;
    - ...







- Enumeração de valores nominais:
  - Os dados categóricos/nominais contêm valores de "etiquetas" em vez de valores numéricos;
  - Podem ser aplicados vários métodos:
    - Label Encoding,
    - One-Hot Encoding,
    - Binary Encoding,



Movie	Genre
Jumanji	Adventure
American Pie	Comedy
Braveheart	Drama
	•••



Movie	Genre
Jumanji	Adventure
American Pie	Comedy
Braveheart	Drama
•••	

#### **Label Encoded**

Movie	Genre	Category
Jumanji	Adventure	0
American Pie	Comedy	1
Braveheart	Drama	2



Movie	Genre
Jumanji	Adventure
American Pie	Comedy
Braveheart	Drama

#### **One-Hot Encoded**

Movie	Adventure	Comedy	Drama
Jumanji	1	0	0
American Pie	0	1	0
Braveheart	0	0	1
•••	•••		



Movie	Genre
Jumanji	Adventure
American Pie	Comedy
Braveheart	Drama
	•••

#### **Label Encoded**

Movie	Genre	Category
Jumanji	Adventure	0
American Pie	Comedy	1
Braveheart	Drama	2

Integer values have a natural ordered relationship between each other. ML models may be able to understand such relationships.


One-Hot Encoded


Movie	Adventure	Comedy	Drama
Jumanji	1	0	0
American Pie	0	1	0
Braveheart	0	0	1
•••	•••		

Categorical features where no such ordinal relationship exists. However, for a huge number of categories...




Enumeração de valores nominais:








Enumeração de valores nominais:




## **Enumeração de Valores Nominais Nominal Value Discretization/Encoding**






### Divisão em Intervalos Binning

- Divisão em intervalos:
  - Transformação de valores contínuos em discretos (bins):
    - Torna o modelo mais robusto e evita o overfitting;
    - Penaliza o desempenho do modelo, uma vez que, sempre que se descartam dados, perde-se conhecimento;








### Divisão em Intervalos Binning

- Divisão em intervalos:
  - o Transformação de valores contínuos em discretos (bins)
    - Torna o modelo mais robusto e evita o overfitting,
    - Penaliza o desempenho do modelo, uma vez que sempre que se descartam dados, perde-se conhecimento;






- Engenharia de atributos:
  - o Processo de criação de novos atributos (features);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;
- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 0 2020/10/29 16:30




- Engenharia de atributos:
  - Processo de criação de novos atributos (features);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;
- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 0 2020/10/29 16:30
    - · Ano, mês, dia
    - Horas, minutos, segundos
    - Dia da semana (quinta-feira)
    - Dia útil ou fim de semana?
    - Dia útil ou feriado?
    - ...



- Engenharia de atributos:
  - o Processo de criação de novos atributos (features);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;
- De um atributo do tipo "data", que conhecimento se pode extrair?
  - 0 2020/10/29 16:30







- Engenharia de atributos:
  - o Processo de criação de novos atributos (features);
  - Aumentar o conhecimento/aumentar o desempenho dos modelos;
- De um atributo com coordenadas geográficas?
  - o 41.561859, -8.397455
    - Localização urbana ou rural?
    - Terra ou mar?
    - Quais as ruas na vizinhança deste ponto?
    - Há escolas/mercados/serviços nas imediações?
    - ...





